



数据

王叙萌

wangxumeng@nankai.edu.cn

课程安排

第1周	第1讲：数据可视化简介	第2讲：数据
第2周	第3讲：感知和认知	第4讲：数据可视化基础（1）
第3周	第5讲：数据可视化基础（2）	实验1：可视化图表研究
第4周	第6讲：可视化生成方法（1）	实验2：制作网页（1）
第5周	第7讲：可视化生成方法（2）	实验2：制作网页（2）
第6周	第8讲：可视化生成方法（3）	实验3：使用可视化工具
第7周	第9讲：跨媒体数据可视化	实验4：可视化流程复现（1）
第8周	第10讲：地理数据可视化	实验4：可视化流程复现（2）
第9周	第11讲：时间数据可视化	实验4：可视化流程复现（3）
第10周	第12讲：空间数据可视化	实验4：可视化流程复现（4）
第11周	第13讲：高维数据可视化	实验5：可视化创作（1）
第12周	第14讲：层次数据可视化	实验5：可视化创作（2）
第13周	第15讲：图数据可视化	实验5：可视化创作（3）
第14周	实验5中期汇报	实验5：可视化创作（4）
第15周	第16讲：交互	实验5：可视化创作（5）
第16周	实验5展示	实验5展示


大数据

- 大且复杂的数据集集合




大数据分析

大科学




大安全




大工程



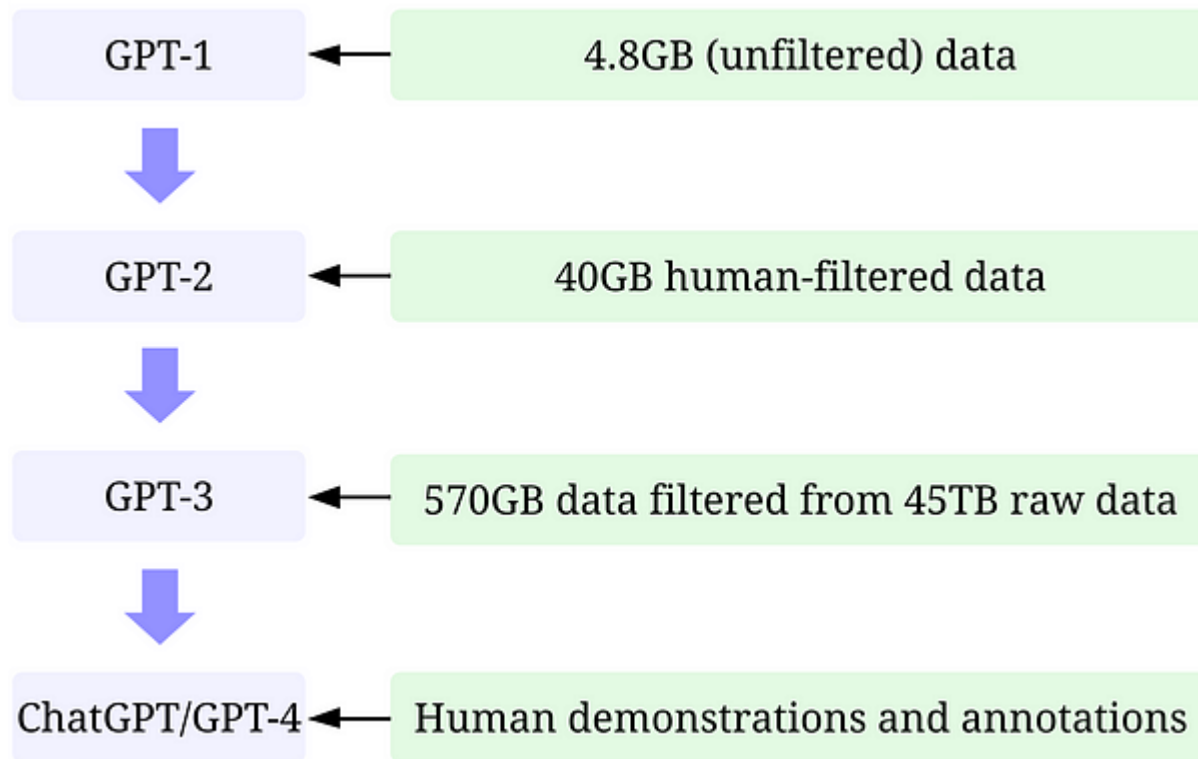
大城市



大网络



大模型背后的大数据



GPT的训练数据演变

大数据

- 体量 (Volume) : 从GB到TB, PB甚至更高
- 速度 (Velocity) : 需要被快速接收和处理
- 种类 (Variety) : 数值、文本、多媒体数据...
- 真实 (Veracity) : 可信度高
- 价值 (Value) : 数据价值高

目录

- 数据类型
- 数据管理

目录

- 数据类型
- 数据管理

按存储分

- 结构化数据（如：规范的表格）
 - 定义：按预定义的数据模型组织的数据
 - 特点：容易处理
- 非结构化数据（如：文本）
 - 定义：没有预定义的数据模型或未按数据模型组织数据
 - 特点：存储灵活

非结构化数据

- 怎么用?

一般需要先处理成结构化数据

表格型数据

- 行：数据记录 (Record)
 - 描述同一个对象的信息
- 列：数据属性 (Attribute) , 也称维度/变量
 - 从同一个角度描述各个对象

学号	性别	年级	成绩	籍贯
1232123	女	大二	84	湖北武汉
3212321	男	大三	91	辽宁大连
2331322	男	大二	75	广东深圳


数据属性 (Attribute)

- 数值型属性 (Numerical)
- 有序型属性 (Ordinal)
- 类别型属性 (Categorical)

学号	性别	年级	成绩	籍贯
1232123	女	大二	84	湖北武汉
3212321	男	大三	91	辽宁大连
2331322	男	大二	75	广东深圳
身份标识	类别型	有序型	数值型	类别型

属性类型

- 数值型属性 (Numerical)
 - 可以测量的数值
 - 例子：数量、重量
 - 分类：离散型/连续型



属性类型

- 有序型属性 (Ordinal)
 - 代表有意义的顺序或排名
 - 例子：考试名次，辣度



属性类型

- 类别型属性 (Categorical)
 - 代表离散的分类
 - 例子：形状，物种
 - 特性：可能存在层次性



脊索动物门	脊索动物门
脊椎动物亚门	脊椎动物亚门
哺乳纲	哺乳纲
真兽亚纲	真兽亚纲
食肉目	食肉目
猫型亚目	裂脚亚目
猫科动物	犬科动物



目录

- 数据类型
- 数据管理

数据管理



数据来源

- 政府公开
- 开源网站
- 数据分析比赛
- 自己收集

政府信息公开



National data 国家数据

中华人民共和国国家统计局
National Bureau of Statistics of China

[首页](#) | [月度数据](#) | [季度数据](#) | [年度数据](#) | [普查数据](#) | [地区数据](#) | [部门数据](#) | [国际数据](#) | [可视化产品](#) | [出版物](#) | [我的收藏](#) | [帮助](#)

查数CHASHU

如：2012年 北京 GDP

搜索

统计热词

GDP CPI 总人口 社会消费品零售总额
粮食产量 PMI PPI

最新发布 (11月14日)

10月份国民经济保持总体平稳 稳中有进发展态势



10月份国民经济保持总体平稳 稳中有进发展态势

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15

更多>>

可视化产品



统计数据产品

图表中国
数据中国[中英]
如何获取统计数据

工作年度报表



数据地图

官方微博(人民 新华 新浪 腾讯) 官方微信

<https://data.stats.gov.cn/>

政府信息公开

可视化图表

可视化统计图秉持方便易用的理念展示统计数字，通过简单的图像或动态界面及互动式统计图，您可更清楚了解一些统计指标。

中国大陆人口钟
China's population clock


1 3 9 3 2 9 9 6 3 4



大中城市住宅销售价格



大中城市主要食品平均价格



中国城镇化进程




中国制造业采购



大中城市房价



大中城市住宅销售价格



中国区域经济情况



房地产投资

政府信息公开



[DATA](#) [TOPICS ▾](#) [IMPACT](#) [APPLICATIONS](#) [DEVELOPERS](#) [CONTACT](#)

The home of the U.S. Government's open data

Here you will find data, tools, and resources to conduct research, develop web and mobile applications, design data visualizations, and [more](#).

GET STARTED

SEARCH OVER [300,722 DATASETS](#)



BROWSE TOPICS



Agriculture



Climate



Consumer



Ecosystems



Education



Energy



Finance



Health



Local
Government



Manufacturing



Maritime



Ocean



Public Safety



Science &
Research

<https://data.gov>

开源网站

Trending Datasets

[See All](#)

World Wide Unicorn Startups

Uzair Rehman · Updated 2 days ago
Usability 7.6 · 13 MB
1 File (CSV)

11



Multimodal Single Cell as Sparse Matrices

Fabien Crom · Updated 8 days ago
Usability 6.3 · 7 GB

19



STOCK PRICE HISTORY TOP 10 COMPANIES

Md Waquar Azam · Updated a month ago
Usability 9.1 · 589 kB
10 Files (CSV)

17



Football Summer Market 2022

David Molina · Updated 2 days ago
Usability 9.1 · 2 MB
2 Files (JSON, CSV)

10

Popular Datasets

[See All](#)

Data Science Job Salaries

Ruchi Bhatia · Updated 3 months ago
Usability 10.0 · 8 kB
1 File (CSV)

869



AMEX data - integer dtypes - parquet format

raddar · Updated 3 months ago
Usability 4.4 · 4 GB
2 Files (other)

663



House Rent Prediction Dataset

Sourav Banerjee · Updated 15 days ago
Usability 10.0 · 84 kB
2 Files (CSV, other)

200



World Population Dataset

Sourav Banerjee · Updated 4 days ago
Usability 10.0 · 18 kB
2 Files (CSV, other)

65

<https://www.kaggle.com/datasets>

开源网站

Default Task	Name	Data Types	Default Task	Attribute Types	# Instances	# Attributes	Year
Classification (88) Regression (50) Clustering (34) Other (11)	 3W dataset	Multivariate, Time-Series	Classification, Clustering	Integer, Real	1984	8	2019
Attribute Type Categorical (0) Numerical (111) Mixed (7)	 Absenteeism at work	Multivariate, Time-Series	Classification, Clustering	Integer, Real	740	21	2018
Data Type - Undo Multivariate (480) Univariate (30) Sequential (59) Time-Series (126) Text (69) Domain-Theory (23) Other (21)	 Activities of Daily Living (ADLs) Recognition Using Binary Sensors	Multivariate, Sequential, Time-Series	Classification, Clustering		2747		2013
Area Life Sciences (18) Physical Sciences (10) CS / Engineering (65) Social Sciences (4) Business (9) Game (2) Other (17)	 Activity Recognition from Single Chest-Mounted Accelerometer	Univariate, Sequential, Time-Series	Classification, Clustering	Real			2014
# Attributes Less than 10 (35) 10 to 100 (50) Greater than 100 (30)	 Activity Recognition system based on Multisensor data fusion (AReM)	Multivariate, Sequential, Time-Series	Classification	Real	42240	6	2016
# Instances Less than 100 (5) 100 to 1000 (24) Greater than 1000 (90)	 AI4I 2020 Predictive Maintenance Dataset	Multivariate, Time-Series	Classification, Regression, Causal-Discovery	Real	10000	14	2020
Format Type Matrix (85) Non-Matrix (41)	 Air Quality	Multivariate, Time-Series	Regression	Real	9358	15	2016
	 Air quality	Multivariate, Time-Series	Regression	Real	9358	15	2016
	 Amazon Access Samples	Time-Series, Domain-Theory	Regression, Clustering, Causal-Discovery		30000	20000	2011
	 Appliances energy prediction	Multivariate, Time-Series	Regression	Real	19735	29	2017

<https://archive.ics.uci.edu/ml/datasets.php>

开源网站



- SNAP for C++ ▶
- SNAP for Python ▶
- SNAP Datasets ▶
- BIOSNAP Datasets
- What's new
- People
- Papers
- Projects ▶
- Citing SNAP
- Links
- About
- Contact us

Open positions

Open research positions in **SNAP** group are available at [undergraduate](#), [graduate](#) and [postdoctoral](#) levels.

Stanford Large Network Dataset Collection

- [Social networks](#) : online social networks, edges represent interactions between people
- [Networks with ground-truth communities](#) : ground-truth network communities in social and information networks
- [Communication networks](#) : email communication networks with edges representing communication
- [Citation networks](#) : nodes represent papers, edges represent citations
- [Collaboration networks](#) : nodes represent scientists, edges represent collaborations (co-authoring a paper)
- [Web graphs](#) : nodes represent webpages and edges are hyperlinks
- [Amazon networks](#) : nodes represent products and edges link commonly co-purchased products
- [Internet networks](#) : nodes represent computers and edges communication
- [Road networks](#) : nodes represent intersections and edges roads connecting the intersections
- [Autonomous systems](#) : graphs of the internet
- [Signed networks](#) : networks with positive and negative edges (friend/foe, trust/distrust)
- [Location-based online social networks](#) : social networks with geographic check-ins
- [Wikipedia networks, articles, and metadata](#) : talk, editing, voting, and article data from Wikipedia
- [Temporal networks](#) : networks where edges have timestamps
- [Twitter and Memetracker](#) : memetracker phrases, links and 467 million Tweets
- [Online communities](#) : data from online communities such as Reddit and Flickr
- [Online reviews](#) : data from online review systems such as BeerAdvocate and Amazon
- [User actions](#) : actions of users on social platforms.
- [Face-to-face communication networks](#) : networks of face-to-face (non-online) interactions
- [Graph classification datasets](#) : disjoint graphs from different classes

SNAP networks are also available from [SuiteSparse Matrix Collection](#) by Tim Davis.

Social networks

Name	Type	Nodes	Edges	Description
ego-Facebook	Undirected	4,039	88,234	Social circles from Facebook (anonymized)
ego-Gplus	Directed	107,614	13,673,453	Social circles from Google+
ego-Twitter	Directed	81,306	1,768,149	Social circles from Twitter
soc-Epinions1	Directed	75,879	508,837	Who-trusts-whom network of Epinions.com
soc-LiveJournal1	Directed	4,847,571	68,993,773	LiveJournal online social network

<http://snap.stanford.edu/data/>

数据分析竞赛

Mini-Challenge 1:



Background

Note: This scenario and all the people, places, groups, technologies, contained therein are fictitious. Any resemblance to real people, places, groups, or technologies is purely coincidental.

In the roughly twenty years that Tethys-based GASTech has been operating a natural gas production site in the island country of Kronos, it has produced remarkable profits and developed strong relationships with the government of Kronos. However, GASTech has not been as successful in demonstrating environmental stewardship.

In January, 2014, the leaders of GASTech are celebrating their new-found fortune as a result of the initial public offering of their very successful company. In the midst of this celebration, several employees of GASTech go missing. An organization known as the Protectors of Kronos (POK) is suspected in the disappearances.

It is January 21, 2014, and as an expert in visual analytics, you have been tasked with helping people understand the complex relationships among people and organizations that may have contributed to these events.

Tasks and Questions:

Mini-Challenge 1 looks at the relationships and conditions that led up to the kidnapping. As an analyst, you have a set of current and historical news reports at your disposal, as well as resumes of numerous GASTech employees and email headers from two weeks of internal GASTech company email. Can you identify the complex relationships among all of these people and organizations?

<https://vast-challenge.github.io/2021/MC1.html>

数据分析竞赛

赛道3：中华古籍数字人文创意（指定数据集）

该赛题要求参赛选手根据给定数据集进行创作。数据集将由专业机构提供若干种能代表中华文化文明传承的少量珍贵古籍样本和目录数据集。鼓励学生跨学科组队，利用前沿信息技术和数字设计工具深度挖掘中华古代典籍的价值，以数字人文作品的新颖形态创造性地展现古籍的文物性、艺术性和知识性，实现“中华传统文化的创造性转化和创新性应用”，让传承数千年的古籍在新时代“活起来”、在全球的文化舞台上火起来。本题目包括两类数据集，参赛选手可以选择其中一部分使用：

（1）**中华古籍原本图片数据集（1.5G）**，左图为原本数据集列表，右图为示例（高福墓誌 唐 王羲之）。使用该类古籍原本数据，需签署使用协议，签字扫描件上传后申请数据下载。协议下载链接：[下载协议](#)、数据申请链接：[申请数据](#)。

王羲之楷书行书系列

黄山寺碑

（唐）李山阴书。唐高宗十八年（730）九月十一日。刻于黄山寺。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）王正书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。

李善兰碑

（唐）李善兰书。唐高宗十八年（730）九月二十六日。刻于李善兰。现存于上海博物馆。



（2）**中华古籍书目数据**：包括舊唐書經籍志、日本國見在書目錄、宋史藝文志、隋書經籍志、新唐書藝文志等。数据下载链接：[古籍书目数据集](#) 下载（约700KB）

<https://chinavis.org/2022/challenge.html>

自己收集

- 途径
 - 导出log
 - 写爬虫
 - 发放问卷
 - ...
- 注意要**合法合规**

数据质量

- 准确性：信息是否存在异常或错误
- 完整性：信息是否存在缺失的状况
- 一致性：相同含义信息在是否一致
- 及时性：从开始处理到可以查看的时间间隔
- 有效性：是否规范，是否符合逻辑
- 唯一性：数据是否不重复

数据质量

- 常见的数据质量问题

- 不合规的值
- 违背了依赖关系
- 身份不唯一
- 记录不唯一
- 信息不完整
- 表述不一

出生日期: 2096-09-00
年 龄: 18

姓名: 张三 学号: 123

姓名: 张四 学号: 123



地址: 10号楼

籍贯: 天津市

籍贯: 天津


提升数据质量的方法1

- 规范数据收集过程



提升数据质量的方法2

- 数据清洗
 - 修复或删除数据集中不正确的、被损坏的、格式错误的、重复的或不完整的数据



数据集成

- 将来自不同数据源的数据整合起来
- 为用户提供统一的接口



数据集成

- 结构冲突
 - 规则不一致
 - 记录不一致
- 数据冲突
 - 重复数据

数据集成

Customer (source 1)

<i>CID</i>	<i>Name</i>	<i>Street</i>	<i>City</i>	<i>Sex</i>
11	Kristen Smith	2 Hurley Pl	South Fork, MN 48503	0
24	Christian Smith	Hurley St 2	S Fork MN	1

Client (source 2)

<i>Cno</i>	<i>LastName</i>	<i>FirstName</i>	<i>Gender</i>	<i>Address</i>	<i>Phone/Fax</i>
24	Smith	Christoph	M	23 Harley St, Chicago IL, 60633-2394	333-222-6542 / 333-222-6599
493	Smith	Kris L.	F	2 Hurley Place, South Fork MN, 48503-5998	444-555-6666

Customers (integrated target with cleaned data)

<i>No</i>	<i>LName</i>	<i>FName</i>	<i>Gender</i>	<i>Street</i>	<i>City</i>	<i>State</i>	<i>ZIP</i>	<i>Phone</i>	<i>Fax</i>	<i>CID</i>	<i>Cno</i>
1	Smith	Kristen L.	F	2 Hurley Place	South Fork	MN	48503-5998	444-555-6666		11	493
2	Smith	Christian	M	2 Hurley Place	South Fork	MN	48503-5998			24	
3	Smith	Christoph	M	23 Harley Street	Chicago	IL	60633-2394	333-222-6542	333-222-6599		24

注意事项

- 操作前备份重要数据
- 操作时仔细检查
- 操作后多次验证

数据存储

- 文件
- 数据库

文件存储

- 半结构化存储

```
1 id,state,county,rate
2 01001,Alabama,Autauga County,5.1
3 01003,Alabama,Baldwin County,4.9
4 01005,Alabama,Barbour County,8.6
5 01007,Alabama,Bibb County,6.2
6 01009,Alabama,Blount County,5.1
7 01011,Alabama,Bullock County,7.1
8 01013,Alabama,Butler County,6.7
9 01015,Alabama,Calhoun County,6.1
10 01017,Alabama,Chambers County,5
11 01019,Alabama,Cherokee County,5
12 01021,Alabama,Chilton County,5.2
13 01023,Alabama,Choctaw County,7.9
14 01025,Alabama,Clarke County,11.1
15 01027,Alabama,Clay County,5.9
16 01029,Alabama,Cleburne County,5.5
```

	A	B	C	D
1	id	state	county	rate
2	1001	Alabama	Autauga C	5.1
3	1003	Alabama	Baldwin Co	4.9
4	1005	Alabama	Barbour Co	8.6
5	1007	Alabama	Bibb Count	6.2
6	1009	Alabama	Blount Cou	5.1
7	1011	Alabama	Bullock Cor	7.1
8	1013	Alabama	Butler Cou	6.7
9	1015	Alabama	Calhoun Co	6.1
10	1017	Alabama	Chambers	5
11	1019	Alabama	Cherokee C	5
12	1021	Alabama	Chilton Cor	5.2
13	1023	Alabama	Choctaw C	7.9
14	1025	Alabama	Clarke Cou	11.1
15	1027	Alabama	Clay Count	5.9
16	1029	Alabama	Cleburne C	5.5

Comma-separated values (.csv)

文件存储

- 半结构化存储

```
1 {  
2   "fruit_array": [  
3     "apple",  
4     "orange",  
5     "banana"  
6   ],  
7   "boolean": true,  
8   "null": null,  
9   "number": 987,  
10  "info": {  
11    "name": "John",  
12    "age": 15  
13  },  
14  "string": "可存字符串"  
15 }
```

JavaScript Object Notation (.json)

文件存储

- 半结构化存储

```
<?xml version="1.0" encoding="UTF-8"?>
<note>
  <to>Tove</to>
  <from>Jani</from>
  <heading>Reminder</heading>
  <body>Don't forget me this
weekend!</body>
</note>
```

Note

To: Tove

From: Jani

Heading: Reminder

Body: Don't forget me this weekend!

Extensible Markup Language (.xml)

文件存储

- 半结构化存储

```
<?xml version="1.0" encoding="UTF-8"?>
<kml xmlns="http://www.opengis.net/kml/2.2">
<Document>
<Placemark>
  <name>New York City</name>
  <description>New York City</description>
  <Point>
    <coordinates>-74.006393,40.714172,0</coordinates>
  </Point>
</Placemark>
</Document>
</kml>
```



Keyhole Markup Language (.kml)

数据库

- 关系型数据库管理系统 (RDBMS)
 - 用于结构化存储、查询、检索存在数据库中数据的软件
- 关系模型
 - 表格-关系
 - 列-属性
 - 行-元组
 - ...

数据库

- 非关系型数据库 (NoSQL)
 - 文件存储: CouchDB, MongoDB
 - 图结构存储: Neo4j, ArangoDB
 - 键值存储: Redis, MongoDB




数据应用

- 数据挖掘：从数据中发现知识
(Knowledge Discovery from Data)
 - 描述任务：描述数据中有的信息
 - 预测任务：派生数据之外的信息



描述任务

- 概念描述：直接描述数据特征
 - 举例：人口普查，财务报表



	Net sales	900 000 000	800 000 000	700 000 000	600 000 000
	Operating income	80 000 000	70 000 000	60 000 000	50 000 000
	Diluted earnings per share	3	2,6	2,2	2
	Cash and cash equivalents	620	560	530	500
	Total assets	620 000	600 000	570 000	540 000
	Total debt	1 750	1 800	1 920	1 830
	Total equity	2 510	2 450	2 340	2 220

描述任务

- 关联分析：分析“特征-值”对在数据中出现的频率
 - 例如：商品推荐



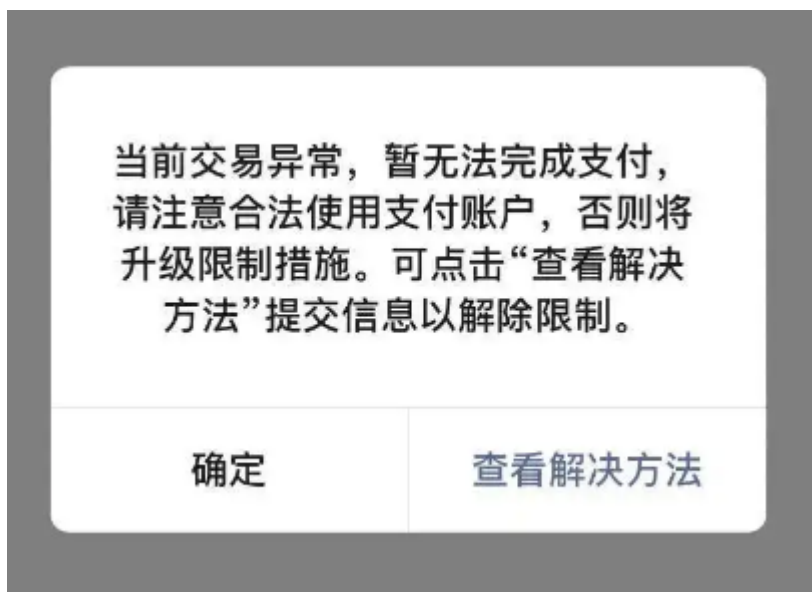
描述任务

- 聚类：按相似度对个体分组
 - 例如：行为分析，物种分析




描述任务

- 异常识别：找出和其他数据不一致的对象
 - 例如：诈骗识别



预测任务

- 分类：找到一个模型/函数可用于区分数据的类别
 - 例如：植物识别，自动驾驶



预测任务

- 演变分析：分析数据的时间和空间模式，用于预测
 - 例如：天气预报，股市分析



数据挖掘方法

- 统计

- 回归、参数估计...



Thomas Bayes

- 机器学习

- 决策树、支持向量机...



John McCarthy

- 算法

- K -means, k -nearest neighbors...



Donald Knuth

基本统计描述

- 提供数据整体概览
- 是探索式数据分析的基础
 - 提供大规模数据分析的切入点

基本统计描述

- 均值

$$\bar{x} = \frac{\sum_{i=1}^N x_i}{N} = \frac{x_1 + x_2 + \cdots + x_N}{N}.$$

- 中位数

$$Q_{\frac{1}{2}}(x) = \begin{cases} x'_{\frac{n+1}{2}}, & \text{if } n \text{ is odd.} \\ \frac{1}{2}(x'_{\frac{n}{2}} + x'_{\frac{n}{2}+1}), & \text{if } n \text{ is even.} \end{cases}$$

- 方差

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

数据挖掘

	Sepal.Length	Sepal.width	Petal.Length	Petal.width	species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5.0	3.4	1.5	0.2	setosa
9	4.4	2.9	1.4	0.2	setosa
10	4.9	3.1	1.5	0.1	setosa



Iris Versicolor



Iris Setosa



Iris Virginica

Iris Dataset

基本统计描述



Iris Versicolor



Iris Setosa



Iris Virginica


类别	Sepal_length		Sepal_width		Petal_length		Petal_width	
	均值	中位数	均值	中位数	均值	中位数	均值	中位数
Setosa	5.006	5.00	3.418	3.40	1.464	1.50	0.244	0.20
Versicolor	5.936	5.90	2.770	2.80	4.260	4.35	1.326	1.30
Virginica	6.588	6.50	2.974	3.00	5.552	5.55	2.026	2.00

基本统计描述

类别\标准差	Sepal_length	Sepal_width	Petal_length	Petal_width
Setosa	0.352490	0.381024	0.173511	0.107210
Versicolor	0.516171	0.313798	0.469911	0.197753
Virginica	0.635880	0.322497	0.551895	0.274650

基本统计描述

- (不)相似性矩阵：数据之间的关联



位置 (不) 相似性


不相似性计算

- 欧式距离：直线距离

$$d_{Euc} = \sqrt{\sum_{i=1}^n |A_i - B_i|^2}$$

- 曼哈顿距离：出租车距离


$$d_{CB} = \sum_{i=1}^n |A_i - B_i|$$



相似性计算

- 余弦相似度






$$S_{\cos} = \frac{A \cdot B}{\|A\| \|B\|}$$



相似性计算

- 皮尔森相关系数：两组变量的线性相关程度

$$S_{\text{pearson}} = \frac{\text{cov}(A, B)}{\sigma_A \sigma_B} = \frac{\sum_{i=1}^N (A_i - \bar{A})(B_i - \bar{B})}{\sigma_A \sigma_B}$$



类别型属性的相似性度量



形状	圆	圆	方	方	三角	三角
颜色	蓝	蓝	红	黄	黄	绿
填充	是	否	是	否	否	是

(不)相似性矩阵怎么算?


统计不匹配属性的个数

类别型属性的相似性度量

						
	0	1	2	3	3	2
	1	0	3	2	2	3
	2	3	0	2	3	2
	3	2	2	0	1	3
	3	2	3	1	0	2
	2	3	2	3	2	0

和可视化的关系？

可视分析







Daniel A. Keim, et al., Visual Analytics: Definition, Process, and Challenges, LNISA '08

探索式数据分析

- 绘制原始数据
- 绘制模型/统计结果
- 多视图协同

Internet Sales

In June of 2014, Europe's Central Bank slashed interest rates into negative territory, a move that was called unconventional and experimental. The central bank pushed rates even deeper into the negative zone this year. That strategy is backfiring, warns Paul Achleitner, chairman of Deutsche Bank.



总结

- 大数据时代
 - 大且复杂，重要
- 数据类型：结构化/非结构化
 - 属性类型：数值型，有序型，类别型
- 数据管理
 - 数据收集/数据存储/数据应用
 - 都可以与可视化/可视分析相关联